Extracción y Selección de Atributos – Protocolos de Validación

Extracción y Selección de Atributos

Los atributos (o *features*) son las variables utilizadas para describir y analizar un conjunto de datos.
Una correcta selección o extracción de atributos mejora la precisión de los modelos, reduce la complejidad computacional y evita el sobreajuste.

a) Extracción de Atributos

Consiste en crear nuevas variables a partir de los datos originales para representar mejor la información.

- Transformaciones matemáticas: logaritmos, raíces, escalado.
- Combinación de variables: sumar, restar o multiplicar atributos para crear otros nuevos.
- Codificación de variables categóricas:
  - *One-hot encoding* (convertir categorías en variables binarias).
  - *Label encoding* (asignar números a categorías).
- Técnicas avanzadas:
  - *PCA (Análisis de Componentes Principales):* reduce dimensiones creando componentes que resumen la varianza de los datos.
  - *TF-IDF (en texto):* mide la relevancia de palabras en documentos.

Ejemplo: en un análisis de vivienda, crear el atributo “precio por metro cuadrado” combinando precio total y superficie.

b) Selección de Atributos

Proceso de elegir las variables más relevantes para entrenar el modelo.

- Métodos de filtrado (Filter):
  - Correlación estadística.
  - Pruebas de significancia (chi-cuadrado, ANOVA).
- Métodos envolventes (Wrapper):
  - Selección secuencial hacia adelante o hacia atrás.
  - Evaluación mediante el desempeño de un modelo.
- Métodos integrados (Embedded):
  - Árboles de decisión y Random Forest (importancia de variables).
  - LASSO (regresión con penalización).

Ejemplo: en la detección de fraudes, priorizar atributos como monto, frecuencia y ubicación de las transacciones, descartando variables irrelevantes.

Protocolos de Validación

La validación es el proceso para comprobar que un modelo o análisis funciona correctamente y que sus resultados son confiables y generalizables.

a) Validación Simple

- Dividir los datos en dos conjuntos:
  - Entrenamiento: para ajustar el modelo.
  - Prueba (test): para evaluar su desempeño. Limitación: los resultados dependen mucho de cómo se dividen los datos.

b) Validación Cruzada (*Cross-validation*)

- k-fold cross-validation: Se divide el conjunto en *k* partes. Se entrena con *k-1* y se prueba con la parte restante, repitiendo el proceso *k* veces.
- Leave-One-Out (LOO): cada observación se utiliza como prueba una vez. Ventaja: más confiable, ya que todos los datos se usan para entrenamiento y validación.

c) Validación con Conjunto de Validación

- Uso de tres subconjuntos:
  - Entrenamiento: para ajustar parámetros.
  - Validación: para ajustar hiperparámetros y evitar sobreajuste.
  - Prueba: para medir el rendimiento final.

d) Bootstrap

- Se generan múltiples muestras con reemplazo a partir del dataset original y se evalúa el modelo en cada una. Útil con conjuntos de datos pequeños.

e) Métricas de Evaluación (según el tipo de modelo)

- Clasificación: Accuracy, Recall, F1-Score, ROC-AUC.
- Regresión: MAE, RMSE, R^2.
- Clustering: Índice de Silhouette, Calinski-Harabasz.

<u>Conclusión</u>

- La extracción y selección de atributos permite representar los datos de forma más eficiente, mejorando la calidad de los modelos.
- Los protocolos de validación son indispensables para garantizar que los resultados obtenidos sean confiables, evitando errores y sobreajuste.
- En conjunto, estos procesos aseguran que la ciencia de datos produzca conclusiones sólidas y útiles para la toma de decisiones.